MÁSTER OFICIAL EN VISIÓN ARTIFICIAL

Seguimiento Visual con Filtros de Partículas

Antonio Sanz Montemayor
antonio.sanz@urjc.es

Juan José Pantrigo Fernández
juanjose.pantrigo@urjc.es

Raúl Cabido Valladolid
raul.cabido@urjc.es

Seguimiento (*tracking*)

- Estimación de los parámetros que definen la cinemática de un sistema en movimiento a lo largo del tiempo.

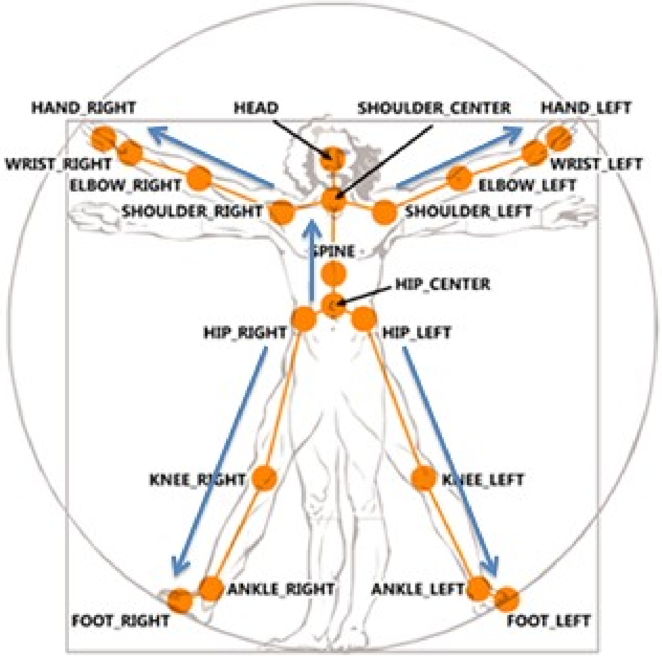

Seguimiento visual

- Localización de uno o varios objetos en movimiento a lo largo del tiempo mediante la interpretación de la información recopilada a través de **dispositivos de captura imágenes**

- Aplicaciones:
  - Interacción persona computador
  - Seguridad y video-vigilancia
  - Realidad aumentada
  - Imagen médica
  - Control de tráfico
  - …

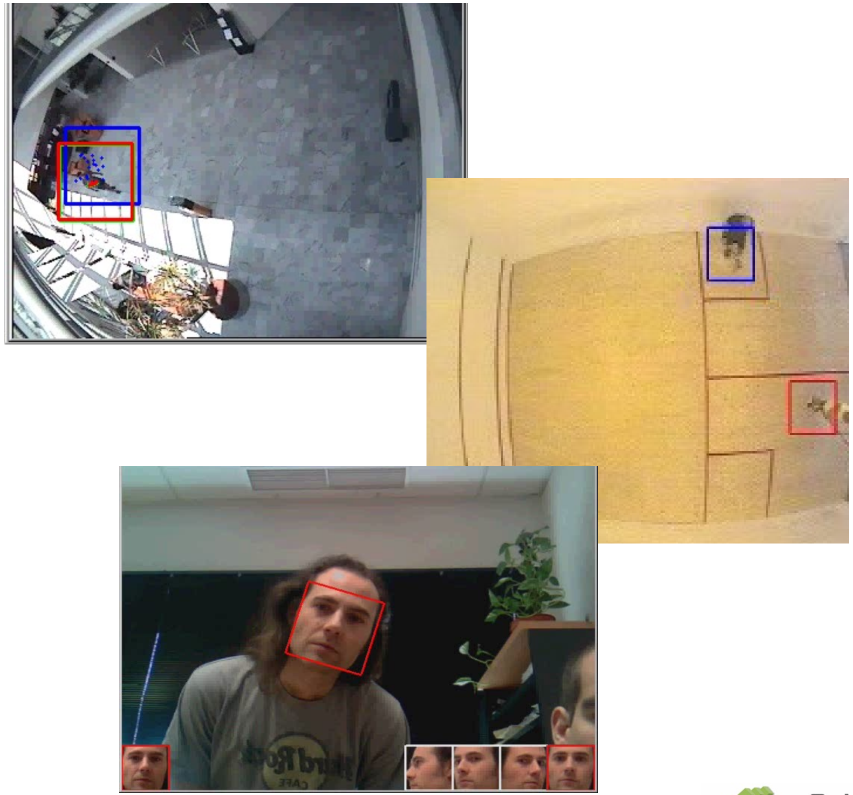

Estimación secuencial: enfoques

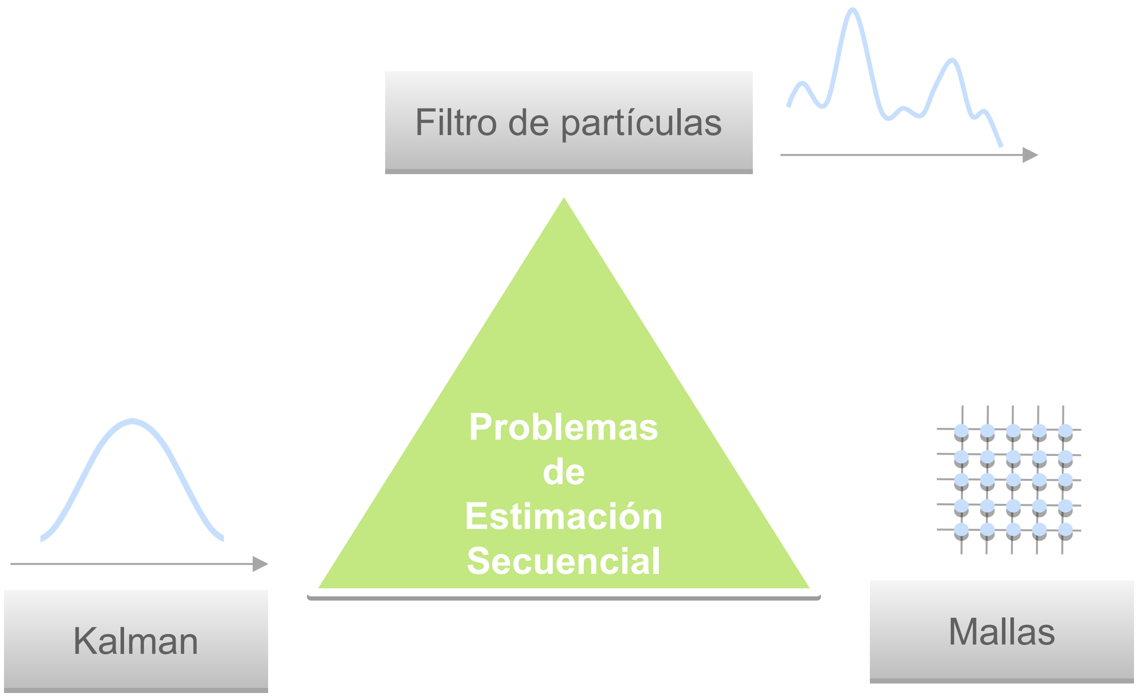

Objetivo

- Estudio de diferentes métodos y su aplicación a la resolución de problemas de seguimiento visual

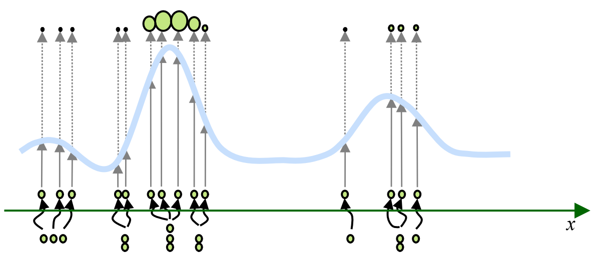

Filtro de partículas

Filtro de Kalman

Estimación secuencial

- El problema de la estimación secuencial, consiste en el cálculo recursivo del estado de un sistema x en el instante t, utilizando para ello observaciones z:
  - Predicción (modelo del sistema)

$$p(x_t|z_{t-1}) = \int p(x_t|x_{t-1})\, p(x_{t-1}|z_{t-1})\, dx_{t-1}$$

  - Actualización (modelo de medida)

$$p(x_t|z_t) = \frac{p(z_t|x_t)\, p(x_t|z_{t-1})}{p(z_t|z_{t-1})}$$

Filtro de partículas (PF)

- Propuesto por Gordon et al. (1993)
  - Isard y Blake (1996) → adaptación para la resolución de problemas de seguimiento
- PF trata de aproximar una función de densidad de probabilidad (*pdf*) que describe el estado de un sistema
- Esta pdf se aproxima mediante un conjunto de muestras discretas llamadas partículas
- Cada partícula p_i representa un posible estado del sistema, x_i, junto con su peso asociado, ω_i, como medida de la verosimilitud de dicho estado:

$$p_i = (x_i, \omega_i)$$

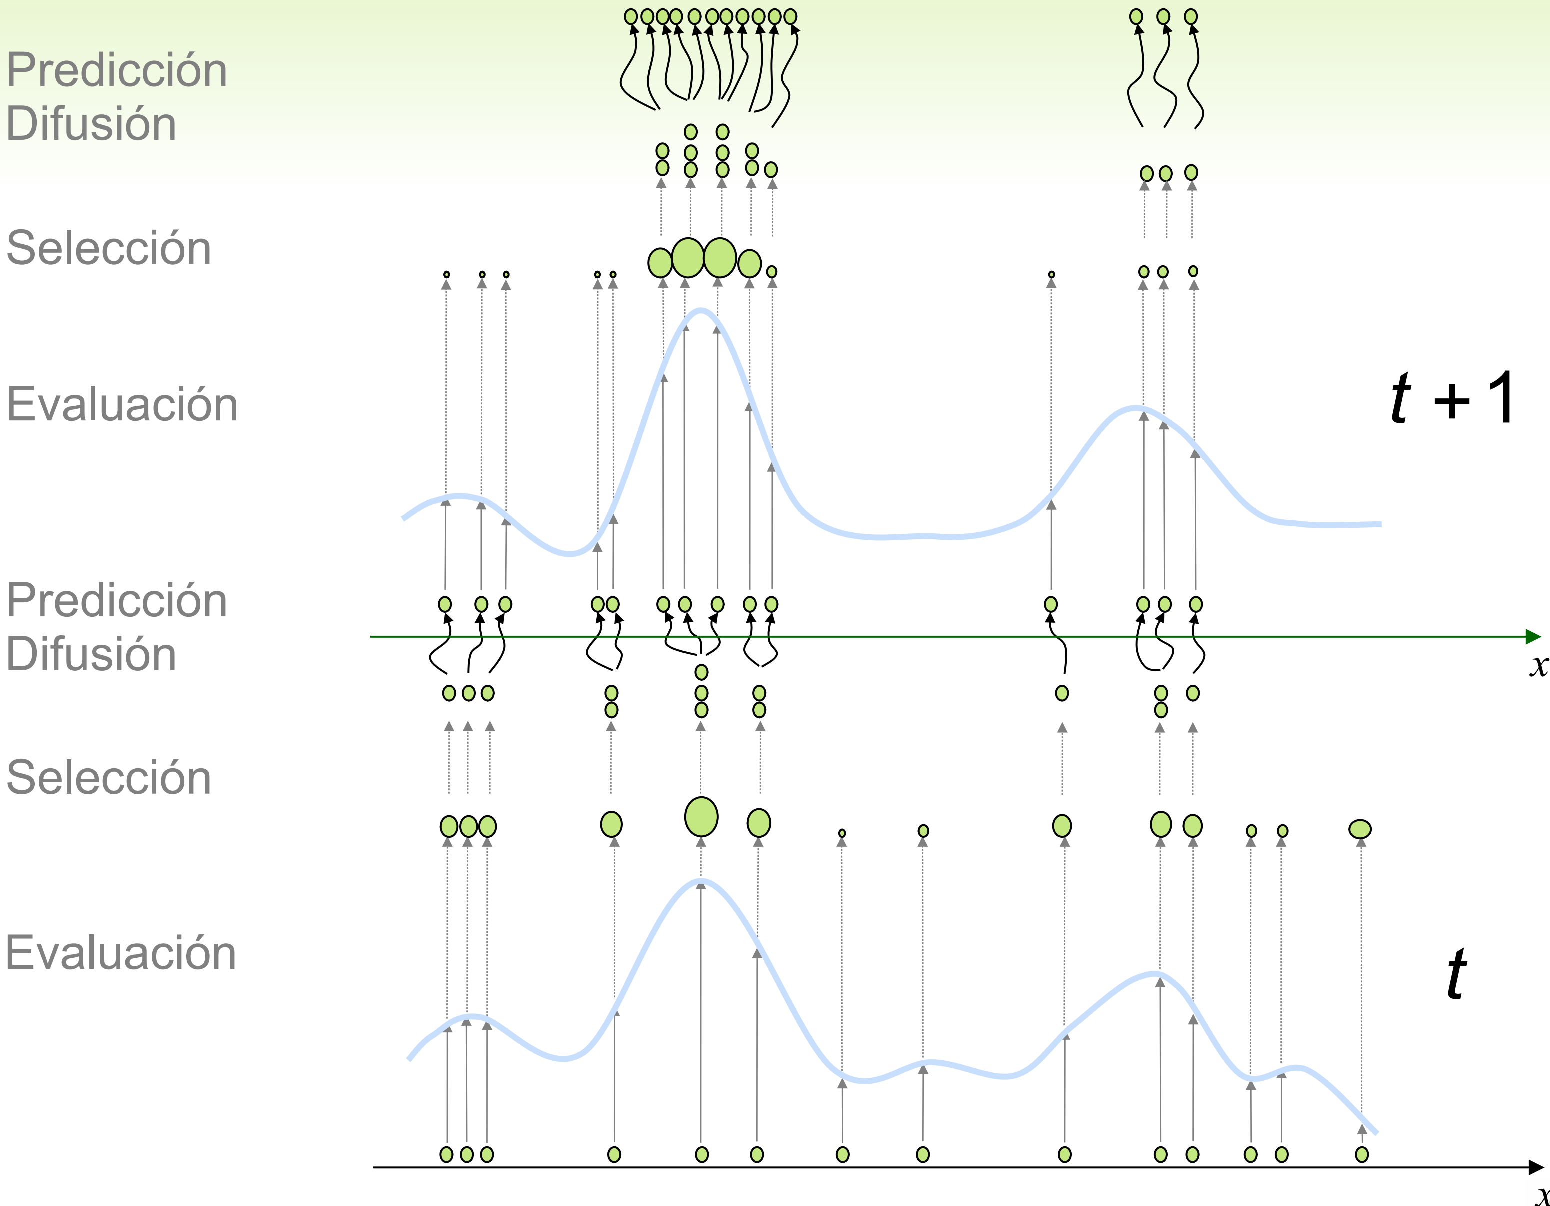
Predicción
Difusión
Selección
Evaluación
$t+1$
x
Predicción
Difusión
Selección
Evaluación
t
x

Filtro de partículas (PF)

predicción

- Selección
- Difusión
- Modelado de movimiento
- Inicialización (casos especiales)

pdf a priori

corrección

- Evaluación

pdf a posteriori

Filtro de partículas

(corrección)

- Inicialización de una población de partículas
  - Caracteriza la ***pdf a priori***

$$\left\{x_t^i, \omega_t^i, i=1,\ldots,N\right\} \qquad \sum_{i=1}^{N} \omega_t^i = 1 \qquad \omega_t^i = \frac{1}{N}, \forall i \in [1, N]$$

- Evaluación:
  - Medida z_t disponible → ***pdf a posteriori***

$$\left\{x_t^i, \omega_t^i, i=1,\ldots,N\right\} \qquad \sum_{i=1}^{N} \omega_t^i = 1$$

  - Tras la evaluación, típicamente $\omega_t^i \neq \omega_t^j, i \neq j$

predicción

Filtro de partículas

- Selección (Remuestreo o *resampling*)
  - Etapa necesaria para evitar el ***fenómeno de la degeneración***: Tras algunos pasos temporales, todas las partículas excepto una tienen pesos despreciables
    - No contribuyen de forma significativa
    - Mucho esfuerzo computacional dedicado a evaluar partículas con peso despreciable
    - La muestra ofrece una representación muy pobre de la *pdf a posteriori*

predicción

Filtro de partículas

- Selección (Remuestreo)
  - Tamaño efectivo de la muestra: mide el número de partículas "útiles":

$$N_{ef} = \frac{1}{\sum_{i=1}^{N} (\omega_t^i)^2}$$

$$si \quad \omega_t^i = \frac{1}{N}, \quad \forall i \in \{1, \ldots, N\} \rightarrow \boxed{N_{ef} = N}$$

$$si \quad \exists j \in \{1, \ldots, N\} \mid \omega_t^j = 1 \rightarrow \boxed{N_{ef} = 1}$$

predicción

Filtro de partículas

- Selección (Remuestreo)
  - Elimina partículas con valores pequeños de peso
  - Multiplica aquéllas con valores mayores

$$\left\{x_t^i, \omega_t^i\right\} \rightarrow \left\{x_{t'}^i, \frac{1}{N}\right\}$$

  - Nueva población
    - Se genera remuestreando con reemplazo N veces
    - Las partículas se seleccionan con probabilidad proporcional a su peso
    - Una manera de implementar el *resampling* es el *método de la ruleta*

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

x_t^1	x_t^2	x_t^3	x_t^4	x_t^5
0.6	0	0.35	0.05	0

$$\left\{ x_t^i, \omega_t^i \right\}$$

Población actual

$$\left\{ x_{t'}^i, \frac{1}{N} \right\}$$

Nueva población

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	0.95	1	1	**Pesos acumulados**
					Nueva población

Filtro de partículas

predicción

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	0.95	1	1	0.63
					Nueva población

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	**0.95**	1	1	0.63
					Nueva población

Filtro de partículas

predicción

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	0.95	1	1	0.63
					Nueva población

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

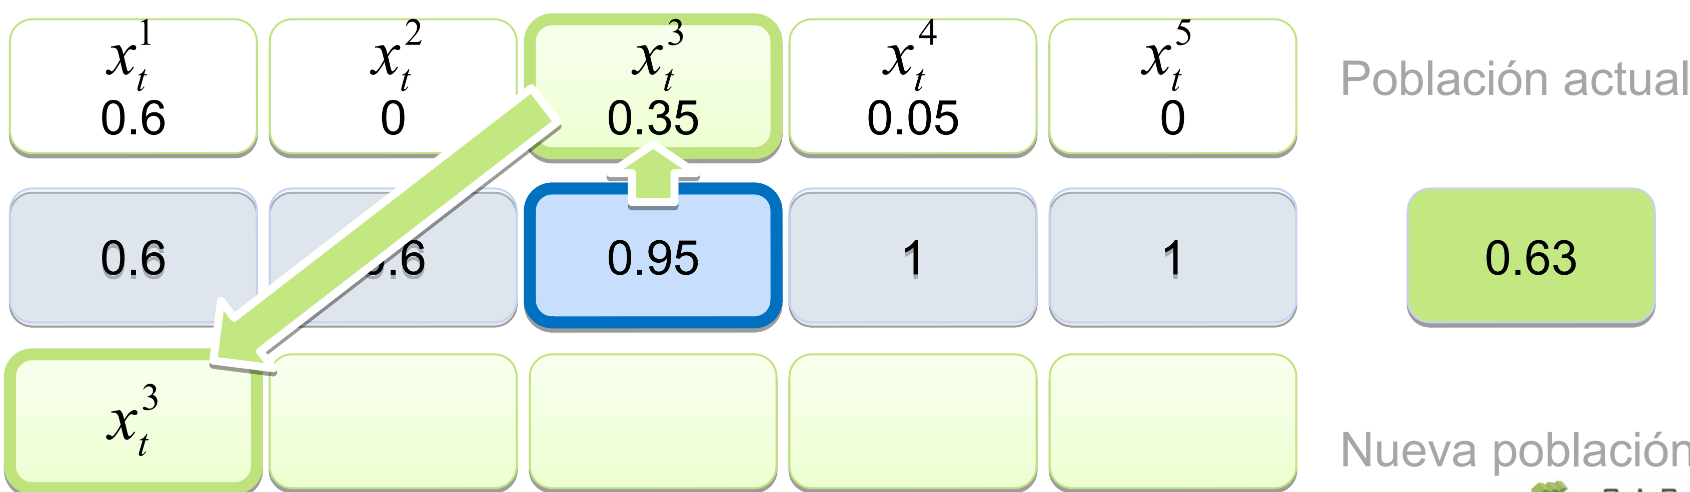

Filtro de partículas

predicción (corrección)

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	0.95	1	1	0.33
x_t^3					Nueva población

Filtro de partículas

predicción

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	0.95	1	1	0.33
x_t^3					Nueva población

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual	
0.6	0.6	0.95	1	1		0.33
x_t^3					Nueva población	

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

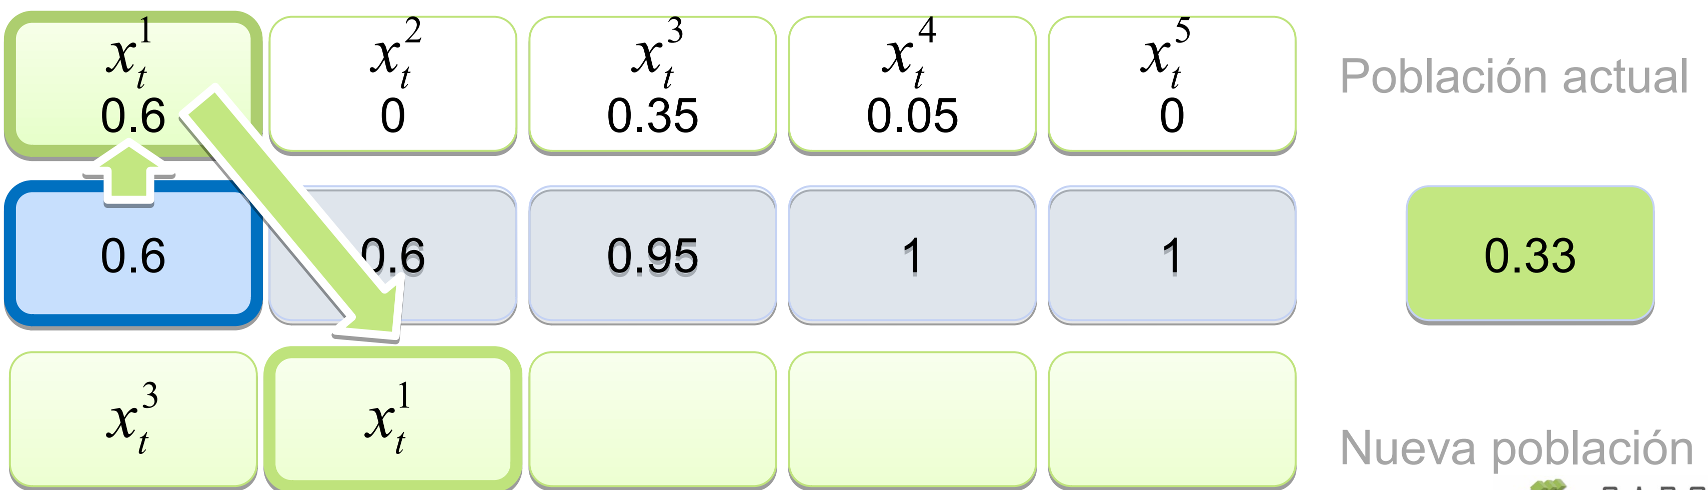

Universidad Rey Juan Carlos

CAPO Computación de Altas Prestaciones y Optimización

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	[illegible]	0.95	1	1	0.12
x_t^3	x_t^1	x_t^1			Nueva población

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

x_t^1 0.6	x_t^2 0	x_t^3 0.35	x_t^4 0.05	x_t^5 0	Población actual
0.6	0.6	0.95	1	1	0.97
x_t^3	x_t^1	x_t^1	x_t^4		Nueva población

predicción

Filtro de partículas

- Selección (*método de la ruleta*)

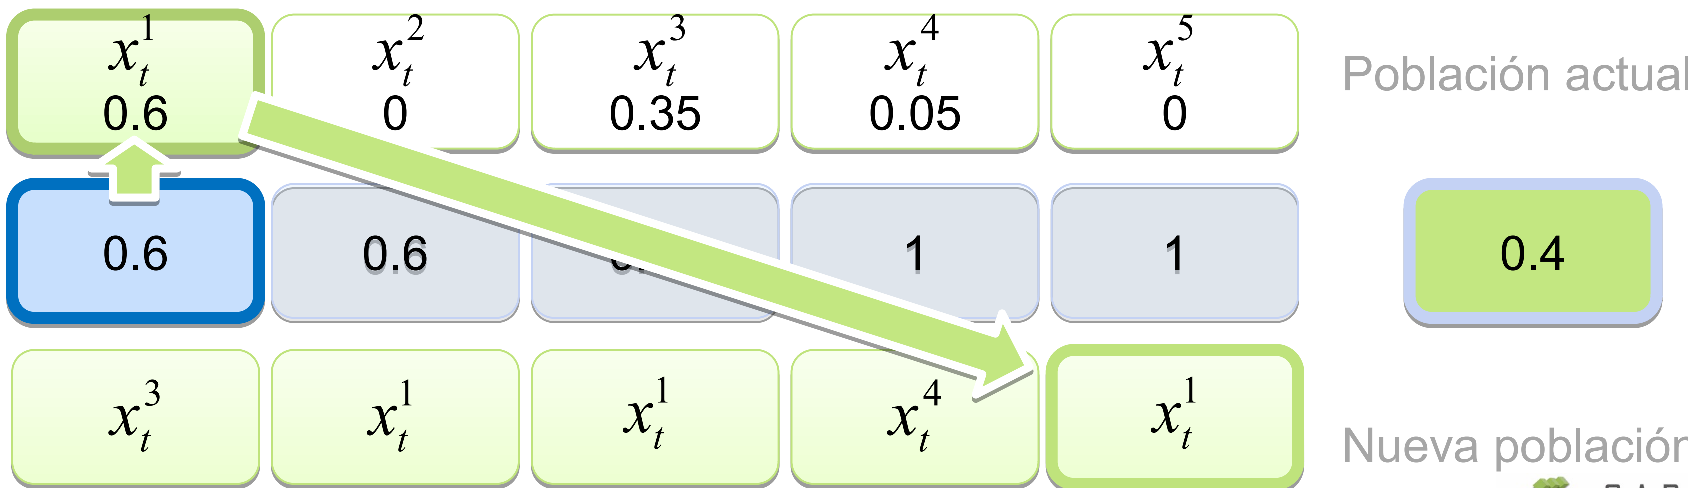

predicción

Filtro de partículas

- Difusión
  - Selección → ***empobrecimiento de la muestra***
  - Aplicar pequeñas perturbaciones sobre el estado de cada partícula seleccionada
    - Por ejemplo, basado en una distribución gaussiana:

$$\left\{ x_{t'}^{i}, \frac{1}{N} \right\} \rightarrow \left\{ x_{t''}^{i}, \frac{1}{N} \right\}$$

$$x_{t''}^{i} = x_{t'}^{i} + \Delta x, \quad \Delta x = \aleph\left(0, \sigma_x\right)$$

Filtro de partículas

predicción

- Modelado de movimiento
  - Aplicar conocimiento acerca de la dinámica del sistema
  - En ausencia de conocimiento, se puede tratar de aprender la dinámica del sistema como parte del proceso
    - Por ejemplo, mediante un modelo autorregresivo gausiano de primer orden:

$$\left\{x_{t''}^{i}, \frac{1}{N}\right\} \rightarrow \left\{x_{t+1}^{i}, \frac{1}{N}\right\}$$

$$x_{t+1}^{i} = x_{t''}^{i} + v_t^{i} + \Delta x, \quad \Delta x = \aleph(0, \sigma_x)$$
$$v_{t+1}^{i} = v_t^{i} + \Delta v_x, \quad \Delta v_x = \aleph(0, \sigma_{vx})$$

PF para seguimiento visual

- En 1996 Isard y Blake adaptaron el marco de trabajo del PF para su aplicación al seguimiento visual
  - CONDENSATION: base de los algoritmos de seguimiento probabilísitico
- Ejemplo: seguimiento de un objeto en el espacio 2D
  - Estado de una partícula:

$$x_t^i = (s_{x,t}^i, s_{y,t}^i)$$

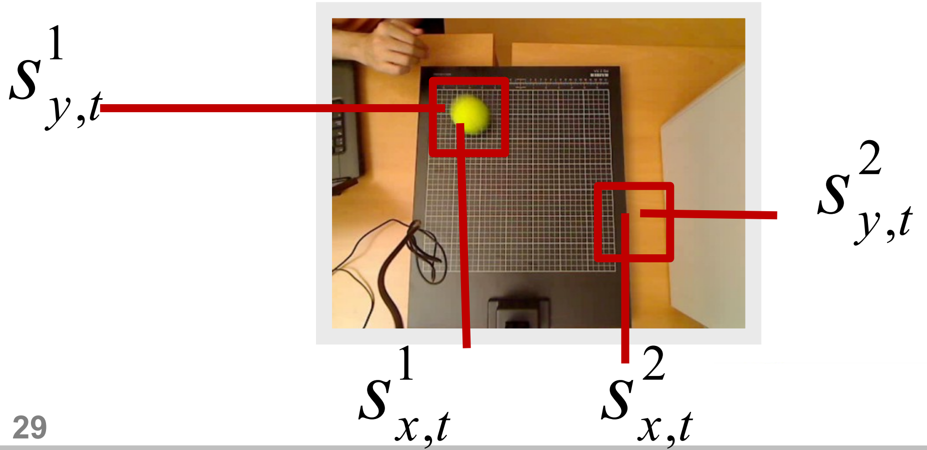

PF para seguimiento visual

Inicialización → Evaluación → Estimación → Selección → Difusión → Predicción

- Inicialización:
  - Muestreo de una función de densidad de probabilidad inicial
    - Generación aleatoria de un conjunto de posiciones 2D

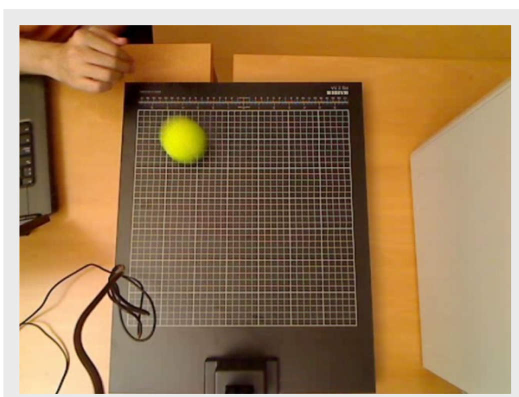

Fotograma inicial t=0

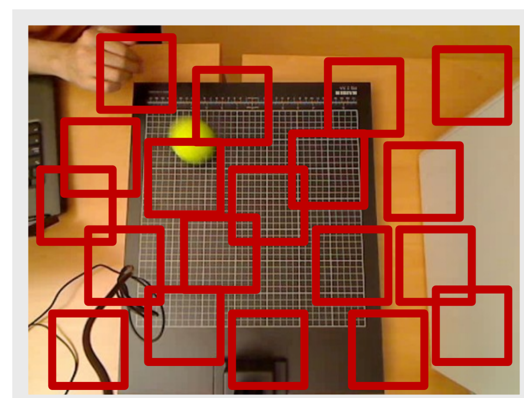

Población inicial

PF para seguimiento visual

Inicialización → **Evaluación** → Estimación → Selección → Difusión → Predicción

- Evaluación:
  - Cálculo del peso de cada partícula utilizando una función de verosimilitud y un modelo de observación (fotograma segmentado)

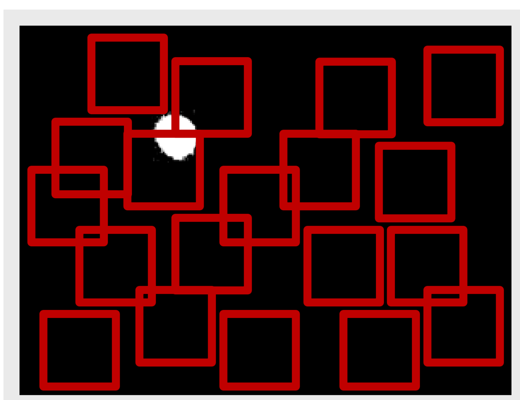

Fotograma t segmentado

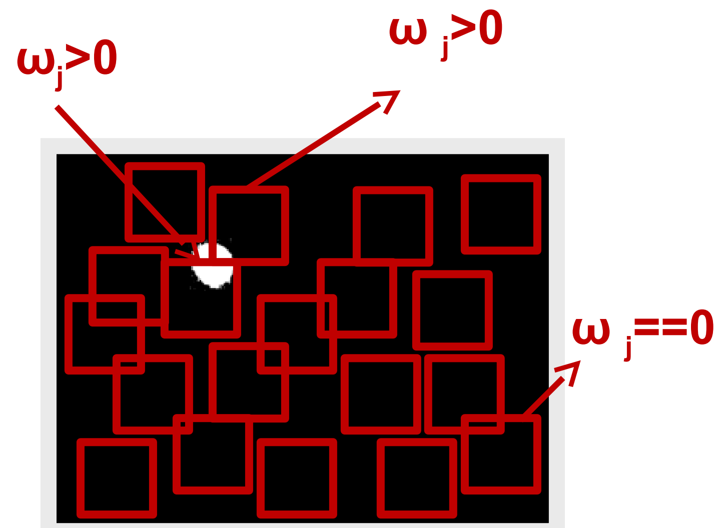

Evaluación de la población

PF para seguimiento visual

Inicialización → Evaluación → **Estimación** → Selección → Difusión → Predicción

- Estimación:
  - *pdf* aproximada mediante medidas discretas
  - Se realizan estimaciones como medias, máximo, etc.
    - Estado más probable → estimado de la posición del móvil

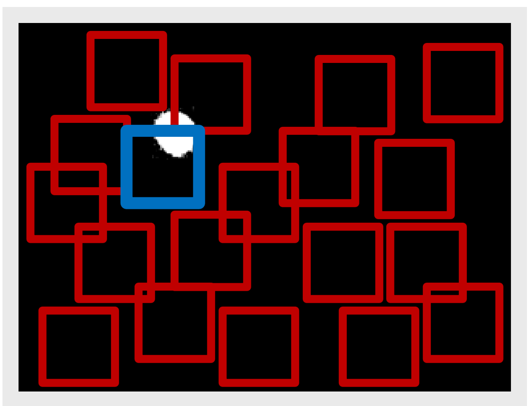

Selección de la partícula con mayor peso

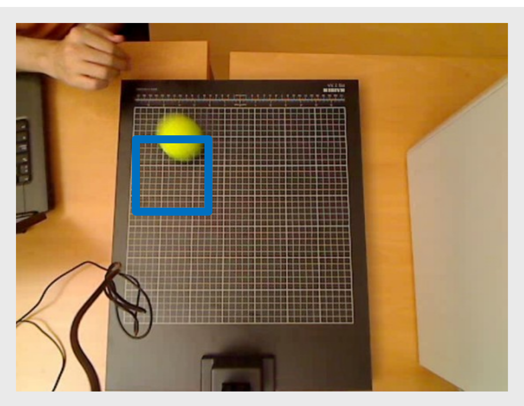

Estimado para el instante *t*

PF para seguimiento visual

Inicialización → Evaluación → Estimación → **Selección** → Difusión → Predicción

- Selección:
  - El nuevo conjunto de partículas se genera remuestreando con reemplazo N veces sobre la población actual
  - La probabilidad de elegir una partícula está directamente relacionada con el valor de su peso

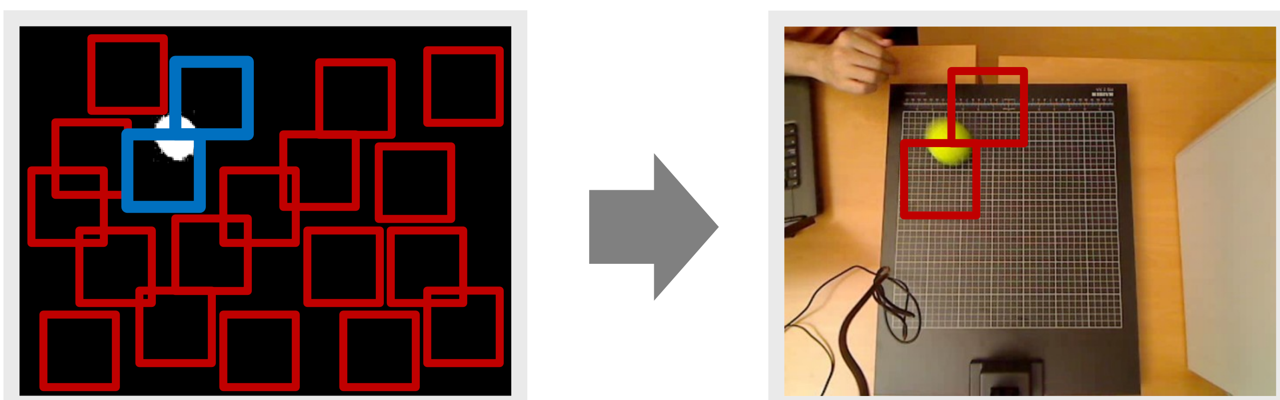

Partículas seleccionadas para generar la nueva población

PF para seguimiento visual

Inicialización → Evaluación → Estimación → Selección → **Difusión** → Predicción

- Difusión:
  - En la etapa de selección las mejores partículas se seleccionan varias veces (empobrecimiento de la muestra)

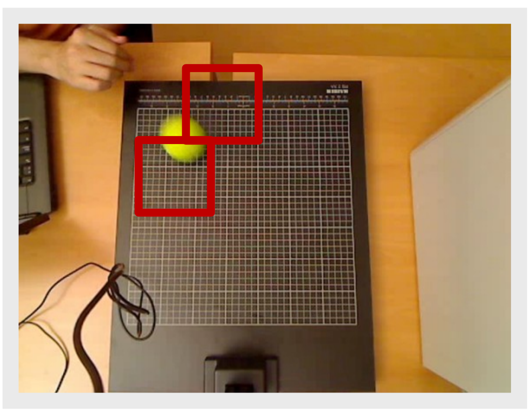

Nueva población con estados repetidos

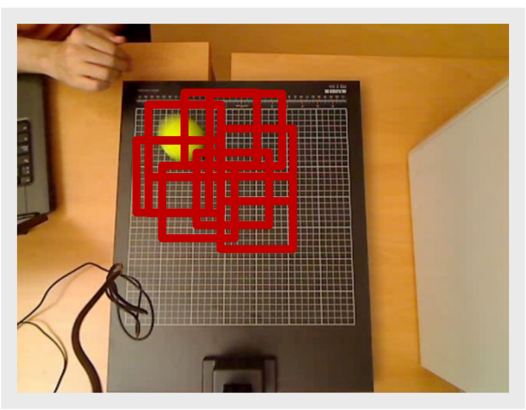

Perturbación aleatoria

PF para seguimiento visual

Inicialización → Evaluación → Estimación → Selección → Difusión → Predicción

- Modelado del movimiento:
  - Se aplica el conocimiento acerca de la dinámica del sistema
  - Tras esta etapa se obtiene la estimación *a priori* de la *pdf* para el siguiente instante de tiempo

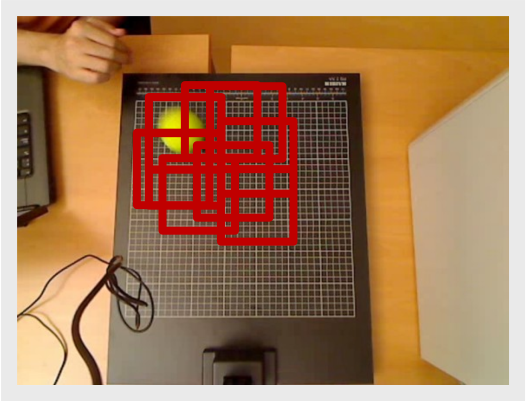

Población de partículas antes de la predicción

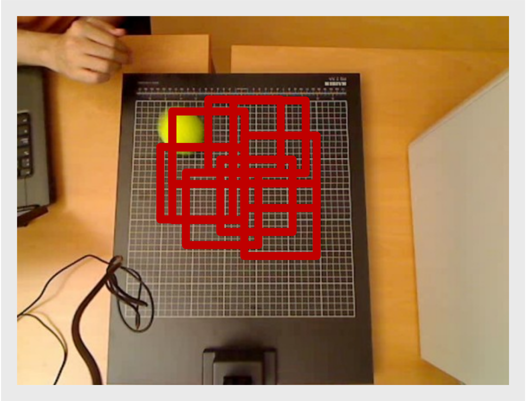

Modelo de sistema conocido y aplicado

PF para seguimiento visual

Inicialización → **Evaluación** → **Estimación** → **Selección** → **Difusión** → **Predicción**

- El proceso se repite nuevamente
  - Se evalúa la nueva población para estimar la posición del objeto en el siguiente fotograma ($t = t + 1$)
  - El proceso se repite para todos los fotogramas de la secuencia

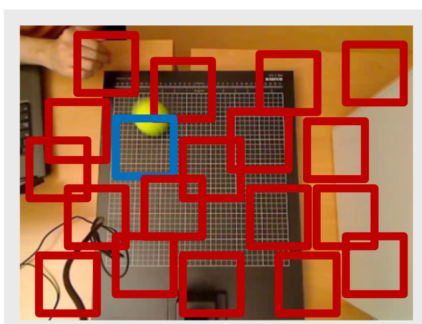

$t = 0$

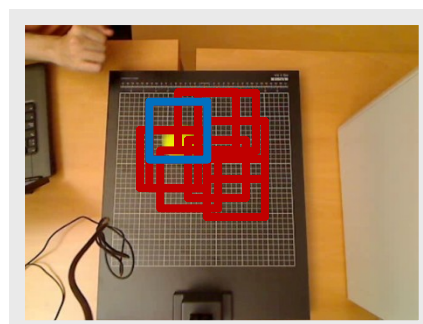

$t = 1$

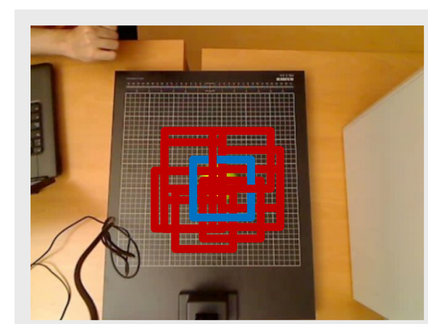

$t = 2$

...

Algoritmo 2.5 *CONDENSATION*

$\{\chi$: **list of** TipoIndividuo$\}$ = $Condensation(N$: integer; $\mathbf{z}_{1:t}$: TipoObservacion);

var

i, t: integer;

x_t: **array** $[1 \ldots N]$ **of** TipoIndividuo$\}$

begin

$t := 1$

$\{\mathrm{x}_t\} := inicializar(N)$;

while not terminacion **do**

/*Evaluar los pesos hasta una constante de normalización*/

$\{\mathrm{x}_t\} := CalcularPesos(\mathrm{x}_t, \mathbf{z}_t)$

$\{\mathrm{x}_t.\omega\} := Normalizar(\mathrm{x}_t.\omega)$;

/*Calcular el estimado*/

$\{\chi[t]\} := CalcularEstimado(\mathrm{x}_t)$;

/*Remuestrear de acuerdo al Algoritmo 2.2*/

$\{\mathrm{x}_t\} := Resampling(\mathrm{x}_t)$;

for $i := 1$ **to** N **do**

$\langle$Predecir por muestreo a partir de $p(\mathrm{x}_{t+1}|\mathrm{x}_t = \mathrm{x}_t^{i*})\rangle$

/*Por ejemplo, el nuevo valor de la muestra puede ser generada a partir de la expresión: $\mathrm{x}_{t+1}[i] = A\mathrm{x}_t[i] + B\mathbf{w}_t[i]$ donde A y B son las matrices que representan las componentes deterministas y estocásticas del modelo dinámico, y $\mathbf{w}_t$ es un vector de muestras de una función de distribución gaussiana*/

end for

$t := t + 1$;

end while

end